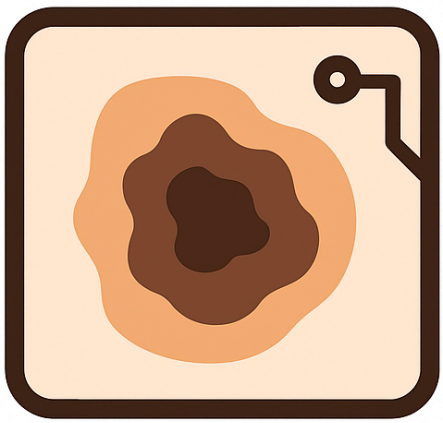


AI SKIN
DERMATOLOGIST

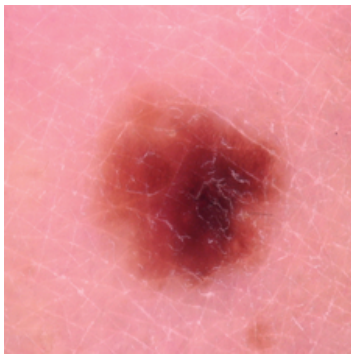
Introduzione:

Abbiamo deciso di concentrarci sul tema della **diagnosi automatica delle lesioni cutanee**. Molte di queste lesioni possono apparire simili a un occhio non esperto, ma in realtà presentano caratteristiche distinte che permettono di distinguerle tra **benigne** (non pericolose) e **maligne** (cancerose).

Questa distinzione è fondamentale per la **prevenzione e diagnosi precoce** del cancro della pelle, uno dei tumori più diffusi al mondo.
L'obiettivo del progetto è quindi quello di **sviluppare un classificatore basato su Intelligenza Artificiale (AI Skin Dermatologist)** in grado di riconoscere automaticamente la natura della lesione partendo da una semplice fotografia.

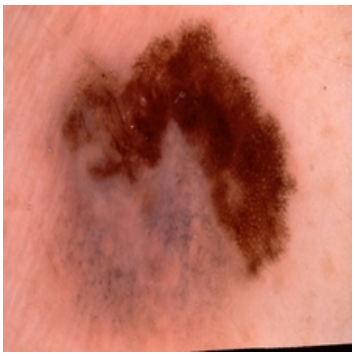
Benigno vs Maligno

Lesioni benigne:



Le lesioni benigne sono tumori non cancerosi. Crescono lentamente, non si diffondono ad altri tessuti e non rappresentano un pericolo per la vita. Esempi comuni includono nei (nevi), cheratosi seborroiche o angiomi.

Lesioni maligne:



Le lesioni maligne invece sono **tumori cancerosi**, caratterizzati da una crescita incontrollata delle cellule e dalla capacità di invadere altri tessuti o metastatizzare.
Il più noto è il **melanoma**, un tumore aggressivo che può diffondersi rapidamente se non diagnosticato in tempo.

La corretta classificazione tra benigno e maligno consente di decidere se è necessaria una **visita dermatologica urgente** o un semplice monitoraggio.

Il Dataset e il Modello

Per addestrare il modello abbiamo utilizzato un **dataset pubblico di immagini dermatologiche** (nel nostro caso da Kaggle: https://www.kaggle.com/datasets/fanconic/skin-cancer-malignant-vs-benign?resource=download).
Il dataset contiene migliaia di fotografie etichettate come **benigne** o **maligne**, con vari tipi di lesioni e tonalità di pelle diverse.

Le 3.297 immagini sono divise in **2.241 per l'addestramento**, **396 per la validazione** e **660 per il test**: la validazione serve a scegliere l'epoca migliore e la soglia, il test viene letto una sola volta alla fine.

Abbiamo scelto di utilizzare una **Convolutional Neural Network (CNN)** per la classificazione, poiché:

a. Le CNN sono in grado di **estrarre automaticamente caratteristiche visive** (texture, bordi, colore, forma) utili a distinguere i diversi tipi di lesione.

b. Sono **invarianti alla traslazione e alla rotazione**, quindi riconoscono la lesione anche se l'immagine è inclinata o zoomata.

Struttura del Modello

Il modello è suddiviso in due parti principali:

1. Feature Extractor

Responsabile dell'estrazione delle caratteristiche visive fondamentali.
Include 5 blocchi di layer, con un numero di canali che cresce da 32 a 512:

- **Conv2d:** per estrarre pattern visivi come bordi o macchie.
- **BatchNorm2d:** per normalizzare i dati e rendere l'addestramento più stabile.
- **ReLU:** per introdurre non-linearità e migliorare l'apprendimento.
- **MaxPool2d:** per ridurre la dimensione spaziale mantenendo le caratteristiche più importanti.

2. Classifier (Fully Connected Layers)

Dopo l'estrazione delle feature, le mappe vengono appiattite e passate a una rete MLP (Multi-Layer Perceptron):

- **Linear(8192, 512) → Linear(512, 128) → Linear(128, 2)**
  (le due classi finali sono: *Benigno*, *Maligno*)
- **Dropout(0.5)** e **Dropout(0.3):** per ridurre l'overfitting.
- **ReLU:** per permettere al modello di imparare relazioni complesse.

La rete lavora su immagini di 128×128 pixel e conta complessivamente 5.831.298 parametri.

Strategie di Ottimizzazione

Per migliorare le prestazioni e la generalizzazione del modello, abbiamo applicato le seguenti tecniche:

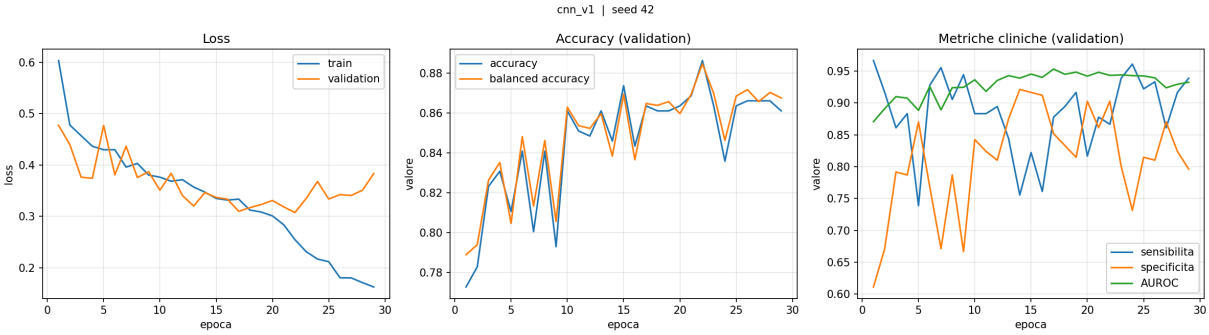
a. **Early Stopping:** il training si interrompe automaticamente se la validazione non migliora per 12 epoche.

b. **Dropout (0.5):** spegne casualmente neuroni durante l'allenamento per evitare l'overfitting.

c. **GPU Detection:** il codice rileva automaticamente la GPU o l'acceleratore migliore per velocizzare l'addestramento.

Risultati

Il modello ha raggiunto un'**accuratezza dell'86,2% sul test set**, con un'**AUROC di 0,942**. La sensibilità (cioè la quota di lesioni maligne correttamente riconosciute) è dell'86,3% e la specificità dell'86,1%: il modello è quindi equilibrato e non privilegia una classe a scapito dell'altra.
Gli errori residui sono spesso dovuti a immagini di scarsa qualità o a lesioni visivamente ambigue (ad esempio nei atipici).



Andamento della loss e delle metriche sulla validazione durante l'addestramento.

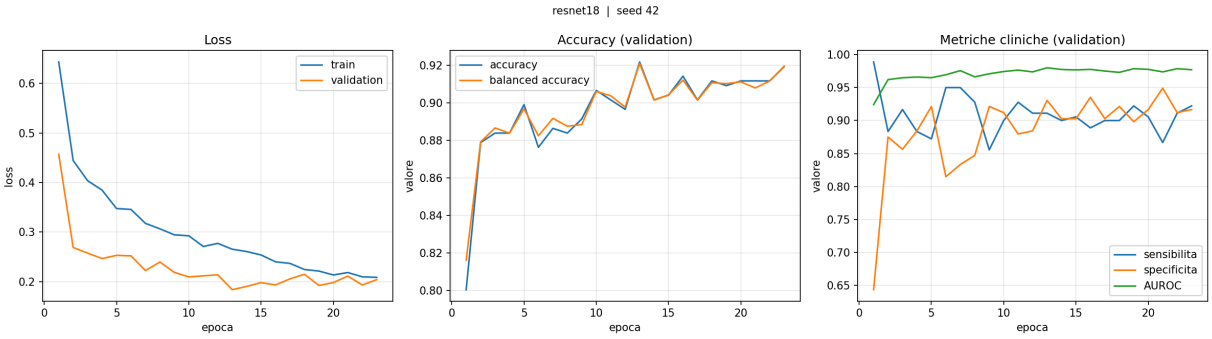
Il classificatore risulta quindi **efficace come strumento di supporto diagnostico**, ma non sostitutivo di una valutazione medica professionale.

Fine-tuning di un modello pre-addestrato

Con circa 2.200 immagini di addestramento, imparare da zero a riconoscere forme e texture è un compito difficile: i primi strati di una rete devono ricostruire nozioni visive molto generali, e per farlo servirebbero molti più esempi. Abbiamo quindi affiancato al nostro modello una seconda soluzione basata sul **transfer learning**.

L'idea è riusare una rete già addestrata su **ImageNet**, un archivio di 1,2 milioni di fotografie, i cui primi strati hanno già imparato a riconoscere bordi, texture e gradienti di colore, utili anche per le lesioni cutanee. Abbiamo preso una **ResNet18** pre-addestrata, sostituito l'ultimo strato con uno a due uscite e proseguito l'addestramento su tutti i parametri con un learning rate ridotto (1e-4). Questa strategia si chiama **fine-tuning completo**: la rete non deve più imparare a vedere, ma solo quali pattern, fra quelli che già distingue, indicano un melanoma.

Le immagini vengono usate alla risoluzione originale di 224×224 pixel, normalizzate con le statistiche di ImageNet e ampliate durante l'addestramento con rotazioni, ribaltamenti e variazioni di luminosità: poiché le lesioni non hanno un orientamento naturale, queste trasformazioni sono lecite e aiutano a generalizzare.



Andamento dell'addestramento della ResNet18: il modello migliore viene raggiunto già alla tredicesima epoca.

I risultati confermano il vantaggio del pre-addestramento:

Modello	Accuratezza	AUROC	Sensibilità	Specificità
CNN progettata da noi	86,2%	0,942	86,3%	86,1%
ResNet18 con fine-tuning	90,0%	0,967	90,3%	89,7%

Il guadagno è di **3,8 punti di accuratezza**, ottenuto per giunta in meno tempo: la ResNet18 raggiunge il suo risultato migliore in 13 epoche, perché parte da pesi già validi invece che da valori casuali.

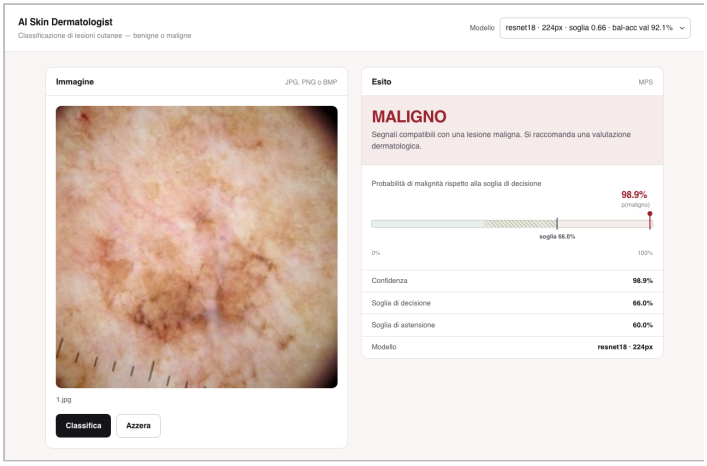
Predictor e Interfaccia

Abbiamo realizzato un **predictor** che:

a. Carica il modello addestrato.

b. Applica una **soglia di decisione** scelta sul validation set, e **si astiene** dichiarando l'esito incerto quando la confidenza scende sotto il 60%.

c. Restituisce la **classe (benigno/maligno)** e la **percentuale di confidenza**.



L'**interfaccia** è stata sviluppata come applicazione web locale, semplice e intuitiva:

- Possibilità di **caricare un'immagine** da file o trascinandola nella pagina.
- Visualizzazione della **foto e del risultato della diagnosi**.
- Rappresentazione grafica della **probabilità di malignità rispetto alla soglia**, con la banda in cui il modello preferisce non esprimersi.
- Possibilità di **scegliere quale dei due modelli** utilizzare.

Conclusioni

AI Skin Dermatologist rappresenta un piccolo passo verso l'uso dell'AI in ambito medico per la **diagnosi precoce del cancro della pelle**.
Pur non sostituendo il dermatologo, può fungere da supporto utile per identificare rapidamente lesioni sospette e incoraggiare controlli tempestivi.